Aspects multi-échelles de l'information : de la physique à la biologie

Thèse dirigée par Giuseppe Longo et Francis Bailly

Boris Saulnier

Equipe Complexité et Information Morphologiques - (Informatique, ENS)

Soutenance de thèse - 15 sept. 2006

Structure de l'argumentation

1. La pratique en bioinformatique semble accréditer l'hypothèse que le formalisme des réseaux génétiques est une représentation complète
2. Mais cette hypothèse de complétude n'est pas explicite et elle n'a pas de justification théorique. Elle ne peut pas être justifiée à partir de l'analyse d'histogrammes
3. De fait, la description phénoménologique autonome à une échelle donnée, d'un phénomène physico-biologique, peut être impossible
4. Néanmoins il existe des lois d'échelles justifiables théoriquement

Structure de l'argumentation

1. La pratique en bioinformatique semble accréditer l'hypothèse que le formalisme des réseaux génétiques est une représentation complète
2. Mais cette hypothèse de complétude n'est pas explicite et elle n'a pas de justification théorique. Elle ne peut pas être justifiée à partir de l'analyse d'histogrammes
3. De fait, la description phénoménologique autonome à une échelle donnée, d'un phénomène physico-biologique, peut être impossible
4. Néanmoins il existe des lois d'échelles justifiables théoriquement

Structure de l'argumentation

1. La pratique en bioinformatique semble accréditer l'hypothèse que le formalisme des réseaux génétiques est une représentation complète
2. Mais cette hypothèse de complétude n'est pas explicite et elle n'a pas de justification théorique. Elle ne peut pas être justifiée à partir de l'analyse d'histogrammes
3. De fait, la description phénoménologique autonome à une échelle donnée, d'un phénomène physico-biologique, peut être impossible
4. Néanmoins il existe des lois d'échelles justifiables théoriquement

Structure de l'argumentation

1. La pratique en bioinformatique semble accréditer l'hypothèse que le formalisme des réseaux génétiques est une représentation complète
2. Mais cette hypothèse de complétude n'est pas explicite et elle n'a pas de justification théorique. Elle ne peut pas être justifiée à partir de l'analyse d'histogrammes
3. De fait, la description phénoménologique autonome à une échelle donnée, d'un phénomène physico-biologique, peut être impossible
4. Néanmoins il existe des lois d'échelles justifiables théoriquement

Structure de l'argumentation

1. La pratique en bioinformatique semble accréditer l'hypothèse que le formalisme des réseaux génétiques est une représentation complète
2. Mais cette hypothèse de complétude n'est pas explicite et elle n'a pas de justification théorique. Elle ne peut pas être justifiée à partir de l'analyse d'histogrammes
3. De fait, la description phénoménologique autonome à une échelle donnée, d'un phénomène physico-biologique, peut être impossible
4. Néanmoins il existe des lois d'échelles justifiables théoriquement

Apports de la thèse

1. Formalisation de la situation expérimentale, dans un cadre méthodologique unifié par les différentes formes entropiques de l'information
2. Explicitation de l'hypothèse de complétude implicite en bioinformatique, et analyse critique de la méthodologie statistique en biologie
3. Interprétation du Second principe de la thermodynamique en termes d'information ; mise en évidence du rôle des échelles dans l'aspect objectif ou subjectif de l'entropie
4. Contribution à la justification théorique des lois d'échelles en biologie (allométrie et métabolisme)

Apports de la thèse

1. Formalisation de la situation expérimentale, dans un cadre méthodologique unifié par les différentes formes entropiques de l'information
2. Explicitation de l'hypothèse de complétude implicite en bioinformatique, et analyse critique de la méthodologie statistique en biologie
3. Interprétation du Second principe de la thermodynamique en termes d'information ; mise en évidence du rôle des échelles dans l'aspect objectif ou subjectif de l'entropie
4. Contribution à la justification théorique des lois d'échelles en biologie (allométrie et métabolisme)

Apports de la thèse

1. Formalisation de la situation expérimentale, dans un cadre méthodologique unifié par les différentes formes entropiques de l'information
2. Explicitation de l'hypothèse de complétude implicite en bioinformatique, et analyse critique de la méthodologie statistique en biologie
3. Interprétation du Second principe de la thermodynamique en termes d'information ; mise en évidence du rôle des échelles dans l'aspect objectif ou subjectif de l'entropie
4. Contribution à la justification théorique des lois d'échelles en biologie (allométrie et métabolisme)

Apports de la thèse

1. Formalisation de la situation expérimentale, dans un cadre méthodologique unifié par les différentes formes entropiques de l'information
2. Explicitation de l'hypothèse de complétude implicite en bioinformatique, et analyse critique de la méthodologie statistique en biologie
3. Interprétation du Second principe de la thermodynamique en termes d'information ; mise en évidence du rôle des échelles dans l'aspect objectif ou subjectif de l'entropie
4. Contribution à la justification théorique des lois d'échelles en biologie (allométrie et métabolisme)

Apports de la thèse

1. Formalisation de la situation expérimentale, dans un cadre méthodologique unifié par les différentes formes entropiques de l'information
2. Explicitation de l'hypothèse de complétude implicite en bioinformatique, et analyse critique de la méthodologie statistique en biologie
3. Interprétation du Second principe de la thermodynamique en termes d'information ; mise en évidence du rôle des échelles dans l'aspect objectif ou subjectif de l'entropie
4. Contribution à la justification théorique des lois d'échelles en biologie (allométrie et métabolisme)

Plan

1. Introduction
   - Objet de la bioinformatique
   - Une hypothèse cachée
2. Inférence et information
   - Approche statique
   - Approche dynamique
3. Information et échelles
   - Echelles en physique
   - Rôle de l'information
4. Lois d'échelles du vivant
   - Le modèle
   - Développement en 4 phases
   - Conséquences

Objet de la bioinformatique

- Acquisition de données :
  - Séquence de l'adn génomique (génome)
  - Concentration des ARN messagers (transcriptome)
  - Concentration, activité, localisation, interaction des protéines (protéome)

Concentr.	t_1	t_2	$\dots$
Gen_1	a_{11}	a_{12}	$\dots$
Gen_2	a_{21}	a_{22}	$\dots$
$\vdots$	$\vdots$	$\vdots$	$\ddots$

Buts

- Calculer les corrélations
- Inférer les états et la dynamique
- Construire le graphe des interactions

Objet de la bioinformatique

- Acquisition de données :
  - Séquence de l'adn génomique (génome)
  - Concentration des ARN messagers (transcriptome)
  - Concentration, activité, localisation, interaction des protéines (protéome)

Concentr.	t_1	t_2	$\dots$
Gen_1	a_{11}	a_{12}	$\dots$
Gen_2	a_{21}	a_{22}	$\dots$
$\vdots$	$\vdots$	$\vdots$	$\ddots$

Buts

- Calculer les corrélations
- Inférer les états et la dynamique
- Construire le graphe des interactions

Des difficultés pratiques

- Erreurs de mesure
- Echantillonnage temporel trop espacé
- Variabilité, reproductibilité
- Faux-positifs

Conséquences

- Querelles sur la reproductibilité et la variabilité
  - Sur fond de grande technicité statistique
- Projets "ontologie", "qualité"
- Connaissances et intuition du biologiste irremplaçables

Et une difficulté également théorique

Hypothèse implicite de complétude causale

- un nombre fini de variables pertinentes régies par des équations autonomes
- à une échelle donnée

Question

Couplage entre les échelles ?

- Autre exemple : mesure échantillonnée de l'activité électrique d'un groupe de neurones : quelle résolution temporelle ?
  - Que penser si l'histogramme évolue dans le temps ou en fonction de l'échelle ?
- Distinguer enjeux théoriques et pratiques

Et une difficulté également théorique

Hypothèse implicite de complétude causale

- un nombre fini de variables pertinentes régies par des équations autonomes
- à une échelle donnée

Question

Couplage entre les échelles ?

- Autre exemple : mesure échantillonnée de l'activité électrique d'un groupe de neurones : quelle résolution temporelle ?
  - Que penser si l'histogramme évolue dans le temps ou en fonction de l'échelle ?
- Distinguer enjeux théoriques et pratiques

Et une difficulté également théorique

Hypothèse implicite de complétude causale

- un nombre fini de variables pertinentes régies par des équations autonomes
- à une échelle donnée

Question

Couplage entre les échelles ?

- Autre exemple : mesure échantillonnée de l'activité électrique d'un groupe de neurones : quelle résolution temporelle ?
  - Que penser si l'histogramme évolue dans le temps ou en fonction de l'échelle ?
- Distinguer enjeux théoriques et pratiques

Et une difficulté également théorique

Hypothèse implicite de complétude causale

- un nombre fini de variables pertinentes régies par des équations autonomes
- à une échelle donnée

Question

Couplage entre les échelles ?

- Autre exemple : mesure échantillonnée de l'activité électrique d'un groupe de neurones : quelle résolution temporelle ?
  - Que penser si l'histogramme évolue dans le temps ou en fonction de l'échelle ?
- Distinguer enjeux théoriques et pratiques

1 Introduction
- Objet de la bioinformatique
- Une hypothèse cachée

2 Inférence et information
- Approche statique
- Approche dynamique

3 Information et échelles
- Echelles en physique
- Rôle de l'information

4 Lois d'échelles du vivant
- Le modèle
- Développement en 4 phases
- Conséquences

Indépendance : une propriété mathématique

(Rappel) Un but en bioinformatique est de calculer des corrélations

- X : l'ensemble des épreuves (peut être non dénombrable)
- $\mathcal{B} \subset \mathcal{P}(X)$ une σ-algèbre de X
- $p : \mathcal{B} \to \mathbb{R}^+$ une mesure finie ($p(\bigcup B_i) = \sum p(B_i)$ si les B_i sont deux-à-deux disjoints)
- B_1 indep. de B_2 si $p(B_1 \cap B_2) = p(B_1)p(B_2)$

Pas de notion d'indépendance, corrélation, hasard et probabilité sans la définition mathématique de $(X, \mathcal{B}, p)$

Exemple

Quelle est la probabilité pour qu'une corde d'un cercle soit à une distance du centre supérieure à $\frac{R}{2}$?

Indépendance : une propriété mathématique

(Rappel) Un but en bioinformatique est de calculer des corrélations

- X : l'ensemble des épreuves (peut être non dénombrable)
- $\mathcal{B} \subset \mathcal{P}(X)$ une σ-algèbre de X
- $p : \mathcal{B} \to \mathbb{R}^+$ une mesure finie ($p(\bigcup B_i) = \sum p(B_i)$ si les B_i sont deux-à-deux disjoints)
- B_1 indep. de B_2 si $p(B_1 \cap B_2) = p(B_1)p(B_2)$

Pas de notion d'indépendance, corrélation, hasard et probabilité sans la définition mathématique de $(X, \mathcal{B}, p)$

Exemple

Quelle est la probabilité pour qu'une corde d'un cercle soit à une distance du centre supérieure à $\frac{R}{2}$?

Indépendance : une propriété mathématique

(Rappel) Un but en bioinformatique est de calculer des corrélations

- X : l'ensemble des épreuves (peut être non dénombrable)
- $\mathcal{B} \subset \mathcal{P}(X)$ une σ-algèbre de X
- $p : \mathcal{B} \to \mathbb{R}^+$ une mesure finie ($p(\bigcup B_i) = \sum p(B_i)$ si les B_i sont deux-à-deux disjoints)
- B_1 indep. de B_2 si $p(B_1 \cap B_2) = p(B_1)p(B_2)$

Pas de notion d'indépendance, corrélation, hasard et probabilité sans la définition mathématique de $(X, \mathcal{B}, p)$

Exemple

Quelle est la probabilité pour qu'une corde d'un cercle soit à une distance du centre supérieure à $\frac{R}{2}$?

Déduire $(X, \mathcal{B}, p)$ d'un histogramme : non

- D un dispositif expérimental. Une expérience produit une valeur dans Ω_1 fini (ou bien dans $\Omega_1 \times \ldots \Omega_p$ fini)
- L'expérience répétée N fois donne l'histogramme des fréquences $p_i = \frac{n_i}{N}$

- $p_i = \lim_{N \to \infty} \frac{n_i}{N}$: ne définit rien
- p_i ne peut dépendre d'un nombre infini de résultats expérimentaux
- Un histogramme ne définit pas une variable aléatoire
- Une variable aléatoire $f : X \to \mathbb{R}$ requière l'existence mathématique de $(X, \mathcal{B}, p)$
- Alors : $p_f(x_i) = \sum_{x \in X : f(x) = x_i} p(x)$ (fréquences accessibles expérimentalement)

L'information : un outil d'inférence

- Si $f : X \to \mathbb{R}$ est une variable aléatoire (et $(X, \mathcal{B}, p)$ l'espace de probabilités)
- Alors on peut définir $p_f(x_i) = \sum_{x \in X : f(x) = x_i} p(x)$ (fréquences accessibles expérimentalement)

Déduire p de f : méthode du maximum d'entropie

- L'entropie de f est : $S_f = -\sum_i p_f(x_i) \log p_f(x_i)$
- On mesure $\mathbb{E}_p(f) = \eta$ (détermine le multiplicateur β)
- Maximiser $-\sum_{x \in X} p(x) \log p(x)$ en respectant la normalisation $\sum_{x \in X} p(x) = 1$
- Multiplicateurs de Lagrange $\Rightarrow p(x) = \frac{e^{-\beta f(x)}}{Z}$ avec $Z = \sum_{x \in X} e^{-\beta f(x)}$
- C'est la distribution la moins biaisée. La statistique f est suffisante si $S_f = S(p)$

L'information : un outil d'inférence

- Si $f : X \to \mathbb{R}$ est une variable aléatoire (et $(X, \mathcal{B}, p)$ l'espace de probabilités)
- Alors on peut définir $p_f(x_i) = \sum_{x \in X : f(x) = x_i} p(x)$ (fréquences accessibles expérimentalement)

Déduire p de f : méthode du maximum d'entropie

- L'entropie de f est : $S_f = -\sum_i p_f(x_i) \log p_f(x_i)$
- On mesure $\mathbb{E}_p(f) = \eta$ (détermine le multiplicateur β)
- Maximiser $-\sum_{x \in X} p(x) \log p(x)$ en respectant la normalisation $\sum_{x \in X} p(x) = 1$
- Multiplicateurs de Lagrange $\Rightarrow p(x) = \frac{e^{-\beta f(x)}}{Z}$ avec $Z = \sum_{x \in X} e^{-\beta f(x)}$
- C'est la distribution la moins biaisée. La statistique f est suffisante si $S_f = S(p)$

1. Introduction
   - Objet de la bioinformatique
   - Une hypothèse cachée
2. Inférence et information
   - Approche statique
   - Approche dynamique
3. Information et échelles
   - Echelles en physique
   - Rôle de l'information
4. Lois d'échelles du vivant
   - Le modèle
   - Développement en 4 phases
   - Conséquences

Approche dynamique

- Approche fréquentiste problématique si $(X, \mathcal{B}, p)$ non défini mathématiquement (section préc.)
- D'où l'idée d'une expérience unique, produisant une série temporelle de données (chap 2 et 3)

La reconstruction des états et de la dynamique est-elle possible ?

Définition formelle d'une source de données

- Capacité de mesure et représentation finies ; donc :
- $\mathcal{A}$: alphabet fini ; $\mathcal{A}^*$: ensemble des mots finis ; $\Omega = \mathcal{A}^{\mathbb{N}}$; $\omega = (\omega_i)_{i \in \mathbb{N}} \in \Omega$
- Source de données : processus stochastique $\mathbb{Y} = \{Y_n\}_{n \in \mathbb{N}}$
- Les réalisations sont des suites $\omega \in \Omega$

Approche dynamique

- Approche fréquentiste problématique si $(X, \mathcal{B}, p)$ non défini mathématiquement (section préc.)
- D'où l'idée d'une expérience unique, produisant une série temporelle de données (chap 2 et 3)

La reconstruction des états et de la dynamique est-elle possible ?

Définition formelle d'une source de données

- Capacité de mesure et représentation finies ; donc :
- $\mathcal{A}$: alphabet fini ; $\mathcal{A}^*$: ensemble des mots finis ; $\Omega = \mathcal{A}^{\mathbb{N}}$; $\omega = (\omega_i)_{i \in \mathbb{N}} \in \Omega$
- Source de données : processus stochastique $\mathbb{Y} = \{Y_n\}_{n \in \mathbb{N}}$
- Les réalisations sont des suites $\omega \in \Omega$

Source vue comme un sys. dyn. invariant

- $d(\omega, \omega') = \sum_{i \in \mathbb{N}} \frac{|\omega_i - \omega'_i|}{2^i}$
- Cylindre : $C(\omega, k) = \{\omega' \in \Omega / \omega'_i = \omega_i \ \forall i = , \ldots, k-1\}$
- $\mathcal{C}$ la σ-algèbre des cylindre
- τ décalage, défini par $\tau(\omega)_i = \omega_{i+1} \ \forall i \in \mathbb{N}$

- Si P est une mesure sur $\mathcal{A}$ alors $\mu(C(\omega, k)) = \prod_{i=0}^{k-1} P(\omega_i)$ définit une mesure invariante sur (Ω, τ)
- (Ω, τ, μ) définit un sys. dyn. invariant

Source vue comme un sys. dyn. invariant

- $d(\omega, \omega') = \sum_{i \in \mathbb{N}} \frac{|\omega_i - \omega'_i|}{2^i}$
- Cylindre : $C(\omega, k) = \{\omega' \in \Omega / \omega'_i = \omega_i \ \forall i = , \ldots, k-1\}$
- $\mathcal{C}$ la σ-algèbre des cylindre
- τ décalage, défini par $\tau(\omega)_i = \omega_{i+1} \ \forall i \in \mathbb{N}$

- Si P est une mesure sur $\mathcal{A}$ alors $\mu(C(\omega, k)) = \prod_{i=0}^{k-1} P(\omega_i)$ définit une mesure invariante sur (Ω, τ)
- (Ω, τ, μ) définit un sys. dyn. invariant

Sys. dyn. vu comme une source

- $(X, \mathcal{B}, T, \mu)$ un système dynamique invariant
- $Z = \{I_0, \ldots, I_{N-1}\}$ une partition mesurable finie de X
- $\mathcal{A} = \{0, \ldots, N-1\}$ un alphabet fini associé à Z ; $\Omega = \mathcal{A}^{\mathbb{N}}$

- $\varphi_Z : X \to \Omega$; $\varphi_Z(x) = \omega \Leftrightarrow T^i(x) \in I_{\omega_i} \; \forall i \in \mathbb{N}$
- Supposer que φ_Z est injective sur les sous-ensembles de X de mesure non nulle

Sys. dyn. vu comme une source

- $(X, \mathcal{B}, T, \mu)$ un système dynamique invariant
- $Z = \{I_0, \ldots, I_{N-1}\}$ une partition mesurable finie de X
- $\mathcal{A} = \{0, \ldots, N-1\}$ un alphabet fini associé à Z ; $\Omega = \mathcal{A}^{\mathbb{N}}$

- $\varphi_Z : X \to \Omega$; $\varphi_Z(x) = \omega \Leftrightarrow T^i(x) \in I_{\omega_i}\ \forall i \in \mathbb{N}$
- Supposer que φ_Z est injective sur les sous-ensembles de X de mesure non nulle

Plusieurs mesures d'information

Entropie de Shannon

Chaque mot $s \in \mathcal{L}_k$ a une probabilité $p(s) = \mu(C(\omega, k))$
$h_\mu = \lim_{k\to\infty} \frac{1}{k} \sum_{s\in\mathcal{L}_k} p(s) \log \frac{1}{p(s)}$

Entropie empirique

$N(s, w) = \sum_{i=0}^{n-l} \delta(s_i^{i+l}, w)$; $P(s, w) = \frac{1}{n-l+1} N(s, w)$;
$\hat{H}_l(s) = -\sum_{w\in\mathcal{A}^l} P(s, w) \log P(s, w)$
$\hat{H}(\omega) = \lim_{l\to\infty} \frac{1}{l} \limsup_{n\to\infty} \hat{H}_l(\omega^n)$

Entropie algorithmique

C : fonction récursive partielle
$IA(s, C) = \min\{|p| / C(p) = s\}$ ($|p|$: longueur du programme p)
$K(\omega) = \limsup_{n\to\infty} \frac{IA(\omega^n)}{n}$

Plusieurs mesures d'information

Entropie de Shannon

Chaque mot $s \in \mathcal{L}_k$ a une probabilité $p(s) = \mu(C(\omega, k))$
$h_\mu = \lim_{k\to\infty} \frac{1}{k} \sum_{s\in\mathcal{L}_k} p(s) \log \frac{1}{p(s)}$

Entropie empirique

$N(s, w) = \sum_{i=0}^{n-l} \delta(s_i^{i+l}, w)$; $P(s, w) = \frac{1}{n-l+1} N(s, w)$;
$\hat{H}_l(s) = -\sum_{w\in\mathcal{A}^l} P(s, w) \log P(s, w)$
$\hat{H}(\omega) = \lim_{l\to\infty} \frac{1}{l} \limsup_{n\to\infty} \hat{H}_l(\omega^n)$

Entropie algorithmique

C : fonction récursive partielle
$IA(s, C) = \min\{|p| / C(p) = s\}$ ($|p|$: longueur du programme p)
$K(\omega) = \limsup_{n\to\infty} \frac{IA(\omega^n)}{n}$

Plusieurs mesures d'information

Entropie de Shannon

Chaque mot $s \in \mathcal{L}_k$ a une probabilité $p(s) = \mu(C(\omega, k))$
$h_\mu = \lim_{k\to\infty} \frac{1}{k} \sum_{s\in\mathcal{L}_k} p(s) \log \frac{1}{p(s)}$

Entropie empirique

$N(s, w) = \sum_{i=0}^{n-l} \delta(s_i^{i+l}, w)$; $P(s, w) = \frac{1}{n-l+1} N(s, w)$;
$\hat{H}_l(s) = -\sum_{w\in\mathcal{A}^l} P(s, w) \log P(s, w)$
$\hat{H}(\omega) = \lim_{l\to\infty} \frac{1}{l} \limsup_{n\to\infty} \hat{H}_l(\omega^n)$

Entropie algorithmique

C : fonction récursive partielle
$IA(s, C) = \min\{|p| / C(p) = s\}$ ($|p|$: longueur du programme p)
$K(\omega) = \limsup_{n\to\infty} \frac{IA(\omega^n)}{n}$

Ces mesures sont équivalentes

Théorème 1

Soit (X, T, μ) un système dynamique invariant fini et Z une partition finie mesurable. Alors

$$\int_X K(x, Z) d\mu(x) = \int_X \hat{H}(x, Z) d\mu(x) = h_\mu(T, Z)$$

où $h_\mu(T, Z)$ est l'entropie de KS

Théorème 2

Si le système est ergodique alors pour μ-presque tout $x \in X$ on a :

$$K(x, Z) = \hat{H}(x, Z) = h_\mu(T, Z)$$

Ces mesures sont équivalentes

Théorème 1

Soit (X, T, μ) un système dynamique invariant fini et Z une partition finie mesurable. Alors

$$\int_X K(x, Z) d\mu(x) = \int_X \hat{H}(x, Z) d\mu(x) = h_\mu(T, Z)$$

où $h_\mu(T, Z)$ est l'entropie de KS

Théorème 2

Si le système est ergodique alors pour μ-presque tout $x \in X$ on a :

$$K(x, Z) = \hat{H}(x, Z) = h_\mu(T, Z)$$

Difficultés de calcul

- Comment savoir si une dynamique est ergodique ?
- Si Z est une partition génératrice alors $K(x, Z) = \hat{H}(x, Z)$ ne dépend pas du choix de Z
  - car $h_\mu(T, Z) = h_\mu(Z)$. Mais pas de méthode automatique pour trouver Z
- L'information algorithmique n'est pas calculable
- $IA(x, n, Z) = IA(\varphi_Z(x)^n) \sim h_\mu(T, Z)n$
  - Si pour x *au hasard* $IA(x, n, Z)$ réalise une droite en fonction de n alors $h_\mu(T, Z)$ est donnée par l'angle de cette droite
  - Mais pour choisir x au hasard il faut une connaissance sur μ
- Production difficile de séries temporelles en biologie moléculaire

La reconstruction nécessite une caractérisation théorique préalable de $(X, \mathcal{B}, \mu, T)$

Difficultés de calcul

- Comment savoir si une dynamique est ergodique ?
- Si Z est une partition génératrice alors $K(x, Z) = \hat{H}(x, Z)$ ne dépend pas du choix de Z
  - car $h_\mu(T, Z) = h_\mu(Z)$. Mais pas de méthode automatique pour trouver Z
- L'information algorithmique n'est pas calculable
- $IA(x, n, Z) = IA(\varphi_Z(x)^n) \sim h_\mu(T, Z)n$
  - Si pour x *au hasard* $IA(x, n, Z)$ réalise une droite en fonction de n alors $h_\mu(T, Z)$ est donnée par l'angle de cette droite
  - Mais pour choisir x au hasard il faut une connaissance sur μ
- Production difficile de séries temporelles en biologie moléculaire

La reconstruction nécessite une caractérisation théorique préalable de $(X, \mathcal{B}, \mu, T)$

Difficultés de calcul

- Comment savoir si une dynamique est ergodique ?
- Si Z est une partition génératrice alors $K(x, Z) = \hat{H}(x, Z)$ ne dépend pas du choix de Z
  - car $h_\mu(T, Z) = h_\mu(Z)$. Mais pas de méthode automatique pour trouver Z
- L'information algorithmique n'est pas calculable
- $IA(x, n, Z) = IA(\varphi_Z(x)^n) \sim h_\mu(T, Z)n$
  - Si pour x *au hasard* $IA(x, n, Z)$ réalise une droite en fonction de n alors $h_\mu(T, Z)$ est donnée par l'angle de cette droite
  - Mais pour choisir x au hasard il faut une connaissance sur μ
- Production difficile de séries temporelles en biologie moléculaire

La reconstruction nécessite une caractérisation théorique préalable de $(X, \mathcal{B}, \mu, T)$

Difficultés de calcul

- Comment savoir si une dynamique est ergodique ?
- Si Z est une partition génératrice alors $K(x, Z) = \hat{H}(x, Z)$ ne dépend pas du choix de Z
  - car $h_\mu(T, Z) = h_\mu(Z)$. Mais pas de méthode automatique pour trouver Z
- L'information algorithmique n'est pas calculable
- $IA(x, n, Z) = IA(\varphi_Z(x)^n) \sim h_\mu(T, Z)n$
  - Si pour x *au hasard* $IA(x, n, Z)$ réalise une droite en fonction de n alors $h_\mu(T, Z)$ est donnée par l'angle de cette droite
  - Mais pour choisir x au hasard il faut une connaissance sur μ
- Production difficile de séries temporelles en biologie moléculaire

La reconstruction nécessite une caractérisation théorique préalable de $(X, \mathcal{B}, \mu, T)$

Difficultés de calcul

- Comment savoir si une dynamique est ergodique ?
- Si Z est une partition génératrice alors $K(x, Z) = \hat{H}(x, Z)$ ne dépend pas du choix de Z
  - car $h_\mu(T, Z) = h_\mu(Z)$. Mais pas de méthode automatique pour trouver Z
- L'information algorithmique n'est pas calculable
- $IA(x, n, Z) = IA(\varphi_Z(x)^n) \sim h_\mu(T, Z)n$
  - Si pour x *au hasard* $IA(x, n, Z)$ réalise une droite en fonction de n alors $h_\mu(T, Z)$ est donnée par l'angle de cette droite
  - Mais pour choisir x au hasard il faut une connaissance sur μ
- Production difficile de séries temporelles en biologie moléculaire

La reconstruction nécessite une caractérisation théorique préalable de $(X, \mathcal{B}, \mu, T)$

Difficultés de calcul

- Comment savoir si une dynamique est ergodique ?
- Si Z est une partition génératrice alors $K(x, Z) = \hat{H}(x, Z)$ ne dépend pas du choix de Z
  - car $h_\mu(T, Z) = h_\mu(Z)$. Mais pas de méthode automatique pour trouver Z
- L'information algorithmique n'est pas calculable
- $IA(x, n, Z) = IA(\varphi_Z(x)^n) \sim h_\mu(T, Z)n$
  - Si pour x *au hasard* $IA(x, n, Z)$ réalise une droite en fonction de n alors $h_\mu(T, Z)$ est donnée par l'angle de cette droite
  - Mais pour choisir x au hasard il faut une connaissance sur μ
- Production difficile de séries temporelles en biologie moléculaire

La reconstruction nécessite une caractérisation théorique préalable de $(X, \mathcal{B}, \mu, T)$

1 Introduction
- Objet de la bioinformatique
- Une hypothèse cachée

2 Inférence et information
- Approche statique
- Approche dynamique

3 Information et échelles
- Echelles en physique
- Rôle de l'information

4 Lois d'échelles du vivant
- Le modèle
- Développement en 4 phases
- Conséquences

Rôle des échelles en physique

- Hypothèse d'équilibre local en thermodynamique linéaire
  - Séparation des variables lentes et rapides (chap. 5)
  - Permet la définition des flux et affinités
- Explication de l'irréversibilité (chap. 6 et 7)
  - Equation de Boltzmann ; théorème H
  - Paradoxes de Loschmidt et Zermelo ; théorème de Liouville
  - Hyp. de chaos moléculaire justifiée par 2 échelles de temps séparées
- Criticité : non séparabilité des échelles (divergence et fluctu.)

- Chap 8 : expression unifiée en termes d'entropie des chap 5 à 7
- Met en évidence la nature relative d'échelle de l'information dans les processus irréversibles

Rôle des échelles en physique

- Hypothèse d'équilibre local en thermodynamique linéaire
  - Séparation des variables lentes et rapides (chap. 5)
  - Permet la définition des flux et affinités
- Explication de l'irréversibilité (chap. 6 et 7)
  - Equation de Boltzmann ; théorème H
  - Paradoxes de Loschmidt et Zermelo ; théorème de Liouville
  - Hyp. de chaos moléculaire justifiée par 2 échelles de temps séparées
- Criticité : non séparabilité des échelles (divergence et fluctu.)

- Chap 8 : expression unifiée en termes d'entropie des chap 5 à 7
- Met en évidence la nature relative d'échelle de l'information dans les processus irréversibles

L'information : un cadre d'interprétation unifié

- L'opérateur densité $\hat{D}$ rassemble toute l'information sur l'ensemble complet des observables du système
- Evolution de $\hat{D}$: $i\hbar\frac{d\hat{D}}{dt} = [\hat{H}, \hat{D}]$ (Liouville-v Neumann)
- Permet les prédictions statistiques : $A \equiv \langle \hat{A} \rangle = Tr\hat{A}\hat{D}$
- Entropie de von Neumann : $S_v(\hat{D}) = -Tr\hat{D}\ln\hat{D}$
- Problème : inférer $\hat{D}$ sur la base des données macroscopiques $A_i = Tr\hat{A}_i\hat{D}$
- Si $S_v(\hat{D}_1) < S_v(\hat{D}_2)$ alors $\hat{D}_1$ est biaisé (il contient trop d'information)

- Résultat : $\hat{D}_R = \exp\left[-\psi - \sum_i \gamma_i \hat{A}_i\right]$
  - Forme exponentielle dûe au log ; concavité entropie $\Rightarrow$unicité

Interprétation géométrique

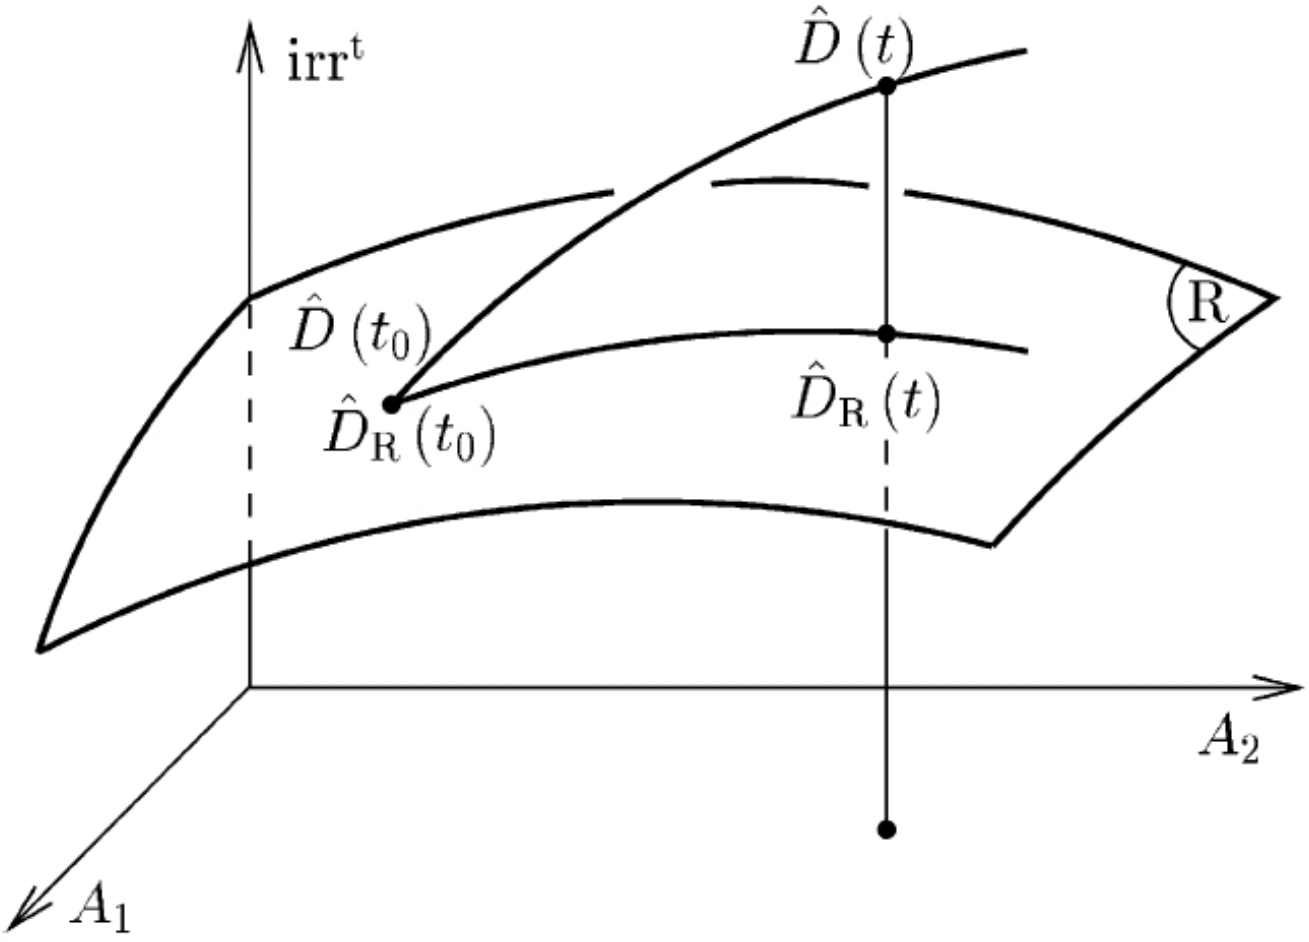

Perte d'information vers les variables non pertinentes

- Etat $\hat{D}$ est représenté par un point dans un espace vectoriel
- Les axes A_1 et A_2 représentent les variables pertinentes $A_i = Tr\hat{A}_i\hat{D}$
- Le troisième axe représente les coordonnées non pertinentes
- La trajectoire de $\hat{D}(t)$ est gouvernée par l'équation de Liouville-von Neumann
- L'état réduit $\hat{D}_R(t)$ est la projection de $\hat{D}(t)$ sur le plan R paramétré par l'ensemble $\{\gamma_i\}$
- L'entropie de von Neumann est constante le long de la trajectoire $\hat{D}(t)$
- Tandis que pour $\hat{D}_R(t)$ l'information est *perdue* vers les degrés de liberté non pertinents

Nature relative de l'entropie

- L'entropie est une information manquante
- L'accroissement de l'entropie correspond à un transfert d'information vers les variables non pertinentes
- A toute échelle, on a
  - des mouvements trop lents qu'on ne voit pas se développer
  - des mouvements rapides ayant déjà relaxé vers leur état stationnaire
  - de nombreux degrés de liberté dont on ne perçoit qu'une moyenne temporelle
- Cas favorable : disposer d'un petit nombre de variables pertinentes, équations autonomes du mouvement (eq. phénoménologiques)
  - Ex : théorème de la chaleur (chap 5) - (P, V, T) modèle complet
- Cas non favorable : échelles couplées

1 Introduction
- Objet de la bioinformatique
- Une hypothèse cachée

2 Inférence et information
- Approche statique
- Approche dynamique

3 Information et échelles
- Echelles en physique
- Rôle de l'information

4 Lois d'échelles du vivant
- Le modèle
- Développement en 4 phases
- Conséquences

Cadre thermodynamique

- Sections 1 et 3 : face au vivant, l'objectivité est à chercher dans le rapport entre les échelles
- Or il existe des lois d'échelle propres au vivant (W_f : la masse adulte)
  - Scaling des durées : $\tau_i \sim u_i W_f^{1/4}$
  - Scaling du métabolisme : $R \sim v_R W_f^{3/4}$
  - De $10^{-13}\,\mathrm{g}$ (micro-organismes) à $10^8\,\mathrm{g}$ ($\frac{\text{galaxie}}{\text{terre}} = 18$; $\frac{\text{chat}}{e^-} = 21$)
- Polémiques statistiques calmées par la construction de modèles multi-échelles
  - ex : travaux de West
- Modèle présenté : l'entropie joue un rôle essentiel

Le modèle

- $G = H - TS$ (énergie libre de Gibbs) ; $H = U + PV$ (enthalpie) ; U (énergie interne)
- R : le métabolisme
- R est la différence entre les flux d'énergie libre entrants et sortants : $R = -\Sigma dx(\mathrm{div} J_G)$
- Equation de conservation : $-\mathrm{div} J_G = \frac{dG}{dt} + T\sigma$
  - σ : vitesse de prod. d'entropie associée au processus irréversible
  - Cf Prigogine, théorie des structures dissipatives

Quatre contributions au métabolisme

- Hypothèse : $S = S^- + S^+$, séparables en fonction de l'échelle de temps considérée
  - $S^- < 0$ (négentropie, processus d'organisation)
  - $S^+ > 0$ (instauration d'un désordre)
- Alors $R = \frac{dH}{dt} - T(\frac{dS^-}{dt} + \frac{dS^+}{dt}) + T\sigma$.
- Enthalpie massique : $H = aW$ (W : masse de l'organisme, a en $(\mathrm{m/s})^2$)
- Alors $R = a\frac{dW}{dt} - T(\frac{dS^-}{dt} + \frac{dS^+}{dt}) + T\sigma$.
- 4 contributions au métabolisme :
  - la variation de la masse
  - l'accroissement de l'organisation (décroissance de S^-)
  - le vieillissement (croissance de S^+)
  - la production d'entropie due à l'irréversibilité du processus global

Trois temps, quatre régimes

- Croissance ago-antagoniste de la masse : $\frac{dW}{dt} = \frac{W}{\tau_W}(1 - \frac{W}{W_f})$
- $\frac{dS^-}{dt} = \frac{S^-}{\tau_{S^-}}(1 - \frac{S^-}{S_f^-})$ (logistique inversée ; organisation croissante, et maximale en fin d'embryogenèse)
- $\tau_W \gg \tau_{S^-}$ (org. max. atteinte avant masse adulte)
- $\frac{dS^+}{dt} = \frac{S^+}{\tau_{S^+}}$ (croissance exponentielle, ex : raccourcissement des téléomères)
- $\tau_{S^+} \gg \tau_W$ (masse adulte atteinte bien avant que ne commence le vieillissement)
- Donc : $\tau_{S^-} \ll \tau_W \ll \tau_{S^+}$. 3 temps caractéristiques qui définissent 4 périodes :
  - Embryogenèse (construction de l'organisation)
  - Croissance de la masse
  - Vie adulte
  - Vieillissement

Expression du métabolisme durant les 4 périodes

- $R_1 \sim a\frac{dW}{dt} - T\frac{dS^-}{dt} + T\sigma_1$
  - effet de S^+ négligeable
- $R_2 \sim a\frac{dW}{dt} + T\sigma_2$
  - l'organisation ne change plus et l'effet du vieillissement demeure négligeable
- $R_3 \sim T\sigma_3$
  - La masse change peu, seuls comptent les échanges avec l'environnement ,qui assurent la stabilité structurelle
- $R_4 \sim -T\frac{dS^+}{dt} + T\sigma_4$
  - L'effet du vieillissement devient prédominant

Conséquence des lois de scaling

- Scaling des durées : $\tau_i \sim u_i W_f^{1/4}$(d'où $\tau_W \sim u_W W_f^{1/4}$)
- Scaling du métabolisme : $R_3 \sim v_R W_f^{3/4}$ (et $R_3 \sim T\sigma_3$)

- Durant périodes 2 et 3 : $R = a\frac{dW}{dt} + T\sigma$ (pas de S^- et S^+)
- Donc (évol. logistique de W) : $R = \frac{a}{\tau_W} W(1 - \frac{W}{W_f}) + T\sigma$
- $\frac{\partial R}{\partial W} = \frac{a}{\tau_W}(1 - 2w) + \frac{\partial \sigma}{\partial W} T$
- La solution la plus simple est : $\frac{\partial R}{\partial W} = \frac{a}{\tau_W}$ et $\frac{\partial \sigma}{\partial W} T = \frac{2aW}{\tau_W}$
- Donc $R \sim \frac{a}{\tau_W} W$. De plus $\tau_W \sim u_W W_f^{1/4}$, donc $R_3 \sim \frac{aW}{u_W W_f^{1/4}} \sim v_R W_f^{3/4}$

Résultat :

$a \sim v_R u_W$

Vérification numérique

- Intégration de l'évolution logistique de la masse :
  - $W(t) = \frac{W_i W_f}{W_i + (W_f - W_i)e^{-T/\tau_W}}$ (W_i : masse initiale)
- Point d'inflexion de la croissance atteint pour t_r tel que $W(t_r) = \frac{W_f}{2}$
- Masse moyenne de l'adulte : $70\,\mathrm{Kg}$; atteinte vers $12\,\mathrm{ans}$
- Ovule fécondé : $1.4 \times 10^{-6}\,\mathrm{g}$ ($\emptyset$ de $140\,\mu\mathrm{m}$ et $1\,\mathrm{Kg/dm^3}$)
- On obtient τ_W =$0.5\,\mathrm{an}$
- D'où u_W =$63\,\mathrm{j/Kg^{1/4}}$
- Par ailleurs R_3 est de $2000\,\mathrm{Kcal/j}$, soit $100\,\mathrm{W}$
- D'où v_R ~$360\,\mathrm{KJ/j.Kg^{3/4}}$

Valeur théorique

$a \sim 22.5\,\mathrm{KJ/g}$

Valeur mesurée

$20\,\mathrm{KJ/g} < a < 26\,\mathrm{KJ/g}$

Vérification numérique

- Intégration de l'évolution logistique de la masse :
  - $W(t) = \frac{W_i W_f}{W_i + (W_f - W_i)e^{-T/\tau_W}}$ (W_i : masse initiale)
- Point d'inflexion de la croissance atteint pour t_r tel que $W(t_r) = \frac{W_f}{2}$
- Masse moyenne de l'adulte : $70\,\mathrm{Kg}$; atteinte vers $12\,\mathrm{ans}$
- Ovule fécondé : $1.4 \times 10^{-6}\,\mathrm{g}$ ($\emptyset$ de $140\,\mu\mathrm{m}$ et $1\,\mathrm{Kg/dm^3}$)
- On obtient τ_W =$0.5\,\mathrm{an}$
- D'où u_W =$63\,\mathrm{j/Kg^{1/4}}$
- Par ailleurs R_3 est de $2000\,\mathrm{Kcal/j}$, soit $100\,\mathrm{W}$
- D'où v_R ~$360\,\mathrm{KJ/j.Kg^{3/4}}$

Valeur théorique

$a \sim 22.5\,\mathrm{KJ/g}$

Valeur mesurée

$20\,\mathrm{KJ/g} < a < 26\,\mathrm{KJ/g}$

Vérification numérique

- Intégration de l'évolution logistique de la masse :
  - $W(t) = \frac{W_i W_f}{W_i + (W_f - W_i)e^{-T/\tau_W}}$ (W_i : masse initiale)
- Point d'inflexion de la croissance atteint pour t_r tel que $W(t_r) = \frac{W_f}{2}$
- Masse moyenne de l'adulte : $70\,\mathrm{Kg}$; atteinte vers $12\,\mathrm{ans}$
- Ovule fécondé : $1.4 \times 10^{-6}\,\mathrm{g}$ ($\emptyset$ de $140\,\mu\mathrm{m}$ et $1\,\mathrm{Kg/dm^3}$)
- On obtient τ_W =0.5 an
- D'où u_W =63 $\mathrm{j/Kg^{1/4}}$
- Par ailleurs R_3 est de $2000\,\mathrm{Kcal/j}$, soit $100\,\mathrm{W}$
- D'où v_R ~360 $\mathrm{KJ/j.Kg^{3/4}}$

Valeur théorique

$a \sim 22.5\,\mathrm{KJ/g}$

Valeur mesurée

$20\,\mathrm{KJ/g} < a < 26\,\mathrm{KJ/g}$

Perspectives

Finir et publier deux articles

- *"A thermodynamic model relating metabolism to allometric scaling coefficients"*
- *"Statistical methodology and scales coupling in molecular biology"*

- Adapter les méthodologies statistiques multi-échelles à l'inférence statistique de la régulation génétique

Travaux à explorer

- Entropies généralisées et superstatistiques
- Relativité d'échelle de L. Nottale
- Criticité et renormalisation ; criticité étendue

Perspectives

Finir et publier deux articles

- "*A thermodynamic model relating metabolism to allometric scaling coefficients*"
- "*Statistical methodology and scales coupling in molecular biology*"

- Adapter les méthodologies statistiques multi-échelles à l'inférence statistique de la régulation génétique

Travaux à explorer

- Entropies généralisées et superstatistiques
- Relativité d'échelle de L. Nottale
- Criticité et renormalisation ; criticité étendue

Perspectives

Finir et publier deux articles

- "*A thermodynamic model relating metabolism to allometric scaling coefficients*"
- "*Statistical methodology and scales coupling in molecular biology*"

- Adapter les méthodologies statistiques multi-échelles à l'inférence statistique de la régulation génétique

Travaux à explorer

- Entropies généralisées et superstatistiques
- Relativité d'échelle de L. Nottale
- Criticité et renormalisation ; criticité étendue

"*Struggle for entropy*" : une clé du vivant ?

The general struggle for existence of living creatures is therefore not one for the basic elements - the elements of all organisms are present in abundance in air, water, and the soil - or for energy, which is unfortunately in abundance in any body in the form of unconvertible heat,
but it is a ***struggle for the entropy*** *that is available through the passage of energy from the hot sun to the cold Earth.*

L. Boltzmann. Populare Schriften. Leipzig, 1905

Apports de la thèse

1. Formalisation de la situation expérimentale, dans un cadre méthodologique unifié par les différentes formes entropiques de l'information
2. Explicitation de l'hypothèse de complétude implicite en bioinformatique, et analyse critique de la méthodologie statistique en biologie
3. Interprétation du Second principe de la thermodynamique en termes d'information ; mise en évidence du rôle des échelles dans l'aspect objectif ou subjectif de l'entropie
4. Contribution à la justification théorique des lois d'échelle en biologie (allométrie et métabolisme)

Merci !

Annexes

Quantité d'information

Approche intuitive

- Spécifier un élément de Ω (fini) : $\log_2 |\Omega|$ bits
- Ou bien $\log_b |\Omega|$ symboles en base b
- $I_\Omega(A) = \log |\Omega| - \log |A| = \log \frac{|\Omega|}{|A|}$
- D'où $I_\Omega(A) = -\log p(A)$

Théorème (Shannon)

- Si la quantité d'incertitude $H_n(p_1, \ldots, p_n)$ vérifie :
  - Continuité (+symétrique et positive)
  - Monotonie : $H_n(\frac{1}{n}, \ldots, \frac{1}{n})$ fonction croissante de n
  - Regroupement : $H_n(p_1, \ldots, p_n) = H_{n-1}(p_1 + p_2, p_2, \ldots, p_n) + (p_1 + p_2) H_2(\frac{p_1}{p_1+p_2}, \frac{p_2}{p_1+p_2})$
- Alors : $H_n = -k \sum_{i=1}^{n} p_i \log p_i$

Quantité d'information

Approche intuitive

- Spécifier un élément de Ω (fini) : $\log_2 |\Omega|$ bits
- Ou bien $\log_b |\Omega|$ symboles en base b
- $I_\Omega(A) = \log |\Omega| - \log |A| = \log \frac{|\Omega|}{|A|}$
- D'où $I_\Omega(A) = -\log p(A)$

Théorème (Shannon)

- Si la quantité d'incertitude $H_n(p_1, \ldots, p_n)$ vérifie :
  - Continuité (+symétrique et positive)
  - Monotonie : $H_n(\frac{1}{n}, \ldots, \frac{1}{n})$ fonction croissante de n
  - Regroupement : $H_n(p_1, \ldots, p_n) = H_{n-1}(p_1 + p_2, p_2, \ldots, p_n) + (p_1 + p_2) H_2(\frac{p_1}{p_1+p_2}, \frac{p_2}{p_1+p_2})$
- Alors : $H_n = -k \sum_{i=1}^{n} p_i \log p_i$

Entropie : une longueur de représentation

$$S_n(p_1, p_2, \ldots, p_n) = -k \sum_i p_i \log p_i$$

Exemple

- Tirage aléatoire : $p_1 = \frac{1}{2}$; $p_2 = \frac{1}{4}$; $p_3 = \frac{1}{8}$; $p_4 = \frac{1}{8} \Rightarrow$ $S_4 = 1,75$ bits
- Code C : $C_1 = \mathbf{0}$; $C_2 = \mathbf{10}$; $C_3 = \mathbf{110}$; $C_4 = \mathbf{111}$
- 1,75 bits nécessaires, en moyenne, pour décrire le résultat d'un tirage

Théorème

Si $L(C) = \mathbb{E}l(X) = \sum_{x \in \mathcal{X}} p(x) l(x)$
alors existe un code C tel que : $H(X) \leq L(C) \leq H(X) + 1$

Entropie : une longueur de représentation

$$S_n(p_1, p_2, \ldots, p_n) = -k \sum_i p_i \log p_i$$

Exemple

- Tirage aléatoire : $p_1 = \frac{1}{2}$; $p_2 = \frac{1}{4}$; $p_3 = \frac{1}{8}$; $p_4 = \frac{1}{8}$ $\Rightarrow$ $S_4 = 1,75$ bits
- Code C : $C_1 = \mathbf{0}$; $C_2 = \mathbf{10}$; $C_3 = \mathbf{110}$; $C_4 = \mathbf{111}$
- 1,75 bits nécessaires, en moyenne, pour décrire le résultat d'un tirage

Théorème

Si $L(C) = \mathbb{E}l(X) = \sum_{x \in \mathcal{X}} p(x)l(x)$
alors existe un code C tel que : $H(X) \leq L(C) \leq H(X) + 1$

Entropie : une longueur de représentation

$$S_n(p_1, p_2, \ldots, p_n) = -k \sum_i p_i \log p_i$$

Exemple

- Tirage aléatoire : $p_1 = \frac{1}{2}$; $p_2 = \frac{1}{4}$; $p_3 = \frac{1}{8}$; $p_4 = \frac{1}{8}$ $\Rightarrow$ $S_4 = 1,75$ bits
- Code C : $C_1 = \mathbf{0}$; $C_2 = \mathbf{10}$; $C_3 = \mathbf{110}$; $C_4 = \mathbf{111}$
- 1,75 bits nécessaires, en moyenne, pour décrire le résultat d'un tirage

Théorème

Si $L(C) = \mathbb{E}l(X) = \sum_{x \in \mathcal{X}} p(x)l(x)$
alors existe un code C tel que : $H(X) \leq L(C) \leq H(X) + 1$

Entropie relative

$$D(p\|q) = \sum_{x \in X} p(x) \log \frac{p(x)}{q(x)}$$

Base d'une géométrie de l'information...

$H(q) = H(p) + D(p\|q)$

...et un outil d'analyse des corrélations

$I(X;Y) = D(p(x,y)\|p(x)p(y)) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x,y) \log \frac{p(x,y)}{p(x)p(y)}$

Entropie relative

$$D(p\|q) = \sum_{x \in X} p(x) \log \frac{p(x)}{q(x)}$$

Base d'une géométrie de l'information...

$H(q) = H(p) + D(p\|q)$

...et un outil d'analyse des corrélations

$I(X;Y) = D(p(x,y)\|p(x)p(y)) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x,y) \log \frac{p(x,y)}{p(x)p(y)}$

Inégalité du traitement de données

- Si X, Y, Z une chaîne de Markov
  - Cad $p(x, y, z) = p(x)p(y|x)p(z|y)$
- Alors $I(X; Y) \geq I(X; Z)$
- Aucun traitement de Y ne peut accroître l'information que Y contient sur X

Conséquences de l'inégalité de Jensen $\mathbb{E}f(X) \geq f(\mathbb{E}X)$

- $D(p\|q) \geq 0$ (égalité ssi $p = q$)
- $I(X;Y) \geq 0$
- L'entropie maximale pour la distribution uniforme
- Subadditivité : $H(X_1, \ldots, X_n) \leq \sum_{i=1}^{n} H(X_i)$
- Concavité : $H(\lambda p_1 + (1-\lambda)p_2) \geq \lambda H(p_1) + (1-\lambda)H(p_2)$
  - Conséquence en phy. : entropie mélange > Σentropies

Réseau

$a>b$
$a>c$
$a>d$
$a>e$
$a>i$
$a>|o|$
$b>l$
$c>l$
$d>|f|$
$d>m$
$d>n$
$e>d$
$e>n$
$e>|g|$
$|f|>|g|$
$|h|>i$
$|j|>k$
$m>n$
$|p|>|q|$
$|s|>|r|$

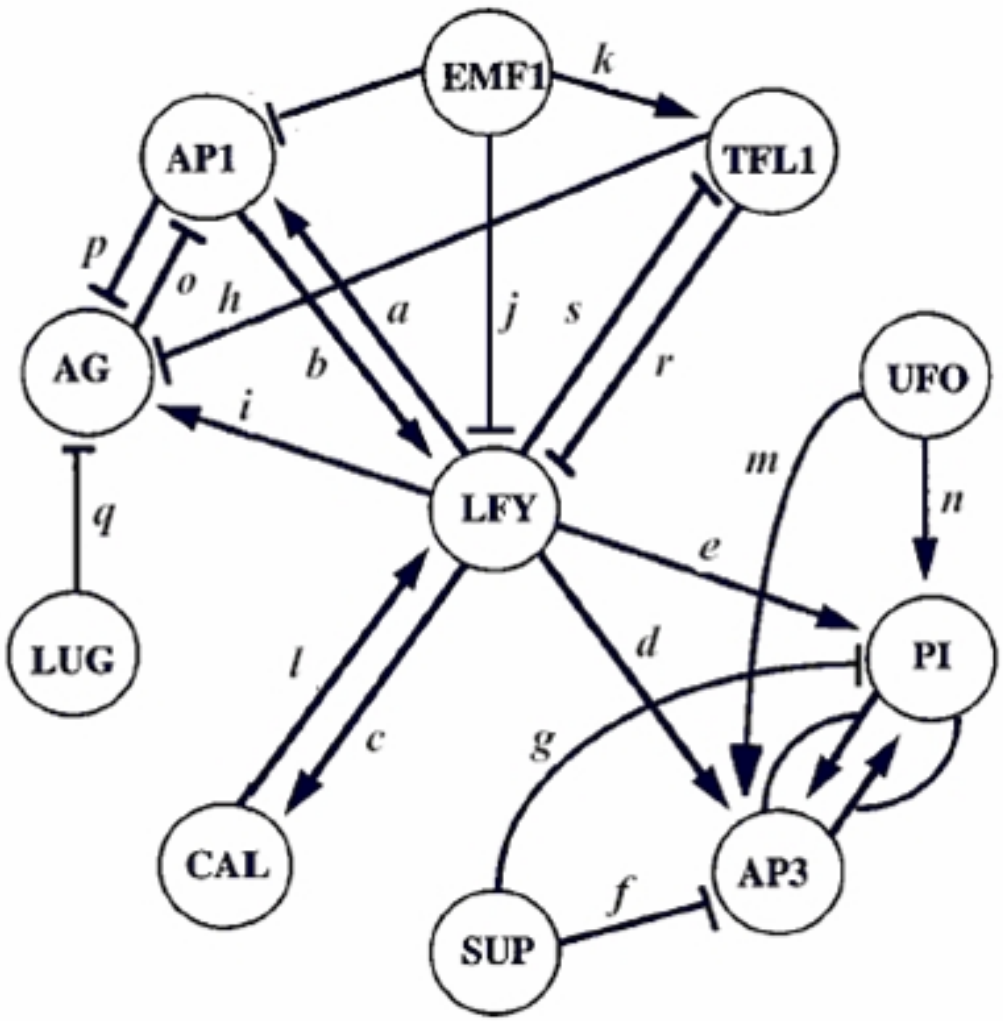

Entropie de Shannon d'une source

- Symboles successifs pas nécessairement indépendants

$\Rightarrow$ Considérer les probas. de blocs de longueur croissante

- $\mathcal{L}_k$: ensemble des mots de longueur k
- Si $\omega^k = s$, chaque mot $s \in \mathcal{L}_k$ a une probabilité $p(s) = \mu(C(\omega, k))$

Entropie de Shannon :

$$\begin{aligned} h_\mu &= \lim_{k\to\infty} \frac{1}{k} \sum_{s\in\mathcal{L}_k} p(s) \log \frac{1}{p(s)} \\ &= \lim_{k\to\infty} \frac{1}{k} \int_\Omega \log \frac{1}{\mu(C(\omega,k))} d\mu(\omega) \end{aligned}$$

Entropie de Shannon d'une source

- Symboles successifs pas nécessairement indépendants

$\Rightarrow$ Considérer les probas. de blocs de longueur croissante

- $\mathcal{L}_k$: ensemble des mots de longueur k
- Si $\omega^k = s$, chaque mot $s \in \mathcal{L}_k$ a une probabilité $p(s) = \mu(C(\omega, k))$

Entropie de Shannon :

$$\begin{aligned} h_\mu &= \lim_{k\to\infty} \frac{1}{k} \sum_{s\in\mathcal{L}_k} p(s) \log \frac{1}{p(s)} \\ &= \lim_{k\to\infty} \frac{1}{k} \int_\Omega \log \frac{1}{\mu(C(\omega,k))} d\mu(\omega) \end{aligned}$$

Entropie de Shannon d'une source

- h_μ est une quantité moyenne d'information par symbole
- h_μ mesure une propriété de la source ; pas d'une suite particulière
- Chaque mot fait partie d'un contexte

Entropie de Shannon :

$$\begin{aligned} h_\mu &= \lim_{k\to\infty} \frac{1}{k} \sum_{s\in\mathcal{L}_k} p(s) \log \frac{1}{p(s)} \\ &= \lim_{k\to\infty} \frac{1}{k} \int_\Omega \log \frac{1}{\mu(C(\omega,k))} d\mu(\omega) \end{aligned}$$

Entropie empirique

Définition

- Soit $s \in \mathcal{A}^n$ un mot de longueur n
- $w \in \mathcal{A}^l$ $(1 \leq l \leq n)$; $s_i^j = (s_i, s_{i+1} \ldots, s_{j-1})$
- $\delta(s_i^{i+l}, w) = \begin{cases} 1 & \text{si } s_i^{i+l} = w \\ 0 & \text{sinon} \end{cases}$
- $N(s, w) = \sum_{i=0}^{n-l} \delta(s_i^{i+l}, w)$
- $P(s, w) = \frac{1}{n-l+1} N(s, w)$
- $\hat{H}_l(s) = -\sum_{w \in \mathcal{A}^l} P(s, w) \log P(s, w)$
- $\hat{H}_l(\omega) = \limsup_{n \to \infty} \hat{H}_l(\omega^n)$
- $\hat{H}(\omega) = \lim_{l \to \infty} \frac{1}{l} \hat{H}_l(\omega)$
- Rq : entropie définie pour un mot unique

Information algorithmique

- C : fonction récursive partielle
- $s \in \mathcal{A}^*$
- $IA(s, C) = \min\{|p| / C(p) = s\}$ ($|p|$: longueur du programme p)
- Théorème : si C et C' sont des machines universelles, alors :

$$\left| IA(s, C) - IA(s, C') \right| \leq K(C, C')$$

$K(C, C')$ est une constante qui dépend de C, C' mais pas de s

Définition

$$K(\omega) = \limsup_{n \to \infty} \frac{IA(\omega^n)}{n}$$

Information algorithmique

- C : fonction récursive partielle
- $s \in \mathcal{A}^*$
- $IA(s, C) = \min\{|p| / C(p) = s\}$ ($|p|$: longueur du programme p)
- Théorème : si C et C' sont des machines universelles, alors :

$$\left| IA(s, C) - IA(s, C') \right| \leq K(C, C')$$

$K(C, C')$ est une constante qui dépend de C, C' mais pas de s

Définition

$$K(\omega) = \limsup_{n \to \infty} \frac{IA(\omega^n)}{n}$$

Etats versus observables

- Soit $\mathcal{A}(X) = \{f : X \to \mathbb{R}\}$ l'ensemble des var aléatoires
- Toute mesure p sur X définit un *état*. Tout état p définit la fonctionnelle linéaire $f \mapsto \mathbb{E}_p(f)$
- Les états forment un sous-ensemble $\Sigma(X)$ du dual de $\mathcal{A}(X)$
- $\lambda p_1 + (1-\lambda)p_2$ est également un état : les états forment un ensemble convexe $(0 < \lambda < 1)$
- Rôle important de l'entropie relative $D(p\|q)$ pseudo-distance dans l'espace des états avec $D(p\|q) = 0$ ssi $p = q$
- Critère du maximum d'entropie : unicité de p assurée par concavité de l'entropie

Physique, biologie, et théorie de l'information

- J. Rothstein, *Information, thermodynamics and life* (1952)
- L. Brillouin, *Science and Information theory* (1956)
- E.T. Jaynes, *Information theory and statistical mechanics* (Phy. Review, 1957)
- H. Atlan, *L'organisation biologique et la théorie de l'information* (1972)
- J. Ricard, Reduction, integration and emergence in biochemical networks (Bio. of the cell, 2004)
- G. Tononi and O. Sporns, Measuring information integration (BMC Neurosciences, 2003)
- ...